



Trabajo práctico 2

Alumnos: Justo Guastavino, Francesca Castronuovo, Isabella Canale

Profesores: María Noelia Romero, Ignacio Anchorena, Tomás Enrique Buscaglia

Grupo 18

Link Github: https://github.com/francastronuovo/-Ciencia_Datos_TP2_Grupo-18

La Encuesta Permanente de Hogares (EPH) es un programa nacional de producción sistemática y continua de información socioeconómica llevado a cabo por el Instituto Nacional de Estadística y Censos (INDEC). Su objetivo principal es relevar las características sociodemográficas y del mercado de trabajo de la población urbana del país, permitiendo realizar análisis comparativos a lo largo del tiempo (INDEC, 2003).

En este trabajo práctico nos enfocamos en el uso de la EPH para analizar la evolución de variables clave entre los primeros trimestres de 2005 y 2025. A diferencia del TP1, que estuvo centrado en la construcción de la variable pobreza y su distribución, en esta segunda instancia el objetivo es visualizar y explorar patrones en la información: histogramas, distribuciones kernel y métodos no supervisados como el Análisis de Componentes Principales (PCA) y el análisis de clusters. Estos métodos permiten sintetizar información de múltiples variables y detectar estructuras subyacentes en los datos, ya sea reduciendo su dimensionalidad (PCA) o agrupando individuos con características similares (clusters). De esta forma, se complementa el enfoque descriptivo tradicional con herramientas que facilitan la exploración de grandes bases de datos y ayudan a identificar regularidades y diferencias entre los períodos analizados.

Parte I: Creación de variables, histogramas, kernels y resumen de la base de datos final

Como primer paso, trabajamos con los microdatos de la EPH correspondientes al primer trimestre de 2005 y 2025. El objetivo fue construir una base final que incluya únicamente las variables presentes en ambos trimestres y que todas ellas estén expresadas de manera homogénea, de modo que los valores sean comparables entre años.

Para ello, comenzamos normalizando los nombres de las variables y unificando los tipos de datos, tomando la estructura del año 2025 como referencia. Posteriormente, aplicamos mapeos de equivalencia en aquellas variables que en 2005 aparecían en formato texto y en 2025 como códigos numéricos. De esta forma, logramos que las categorías tengan un único esquema de valores. Entre las variables que requirieron este procedimiento se encuentran: sexo (CH04), que en 2005 aparecía como “Varón/Mujer” y en 2025 como 1/2. En la variable que incluye la ciudad del individuo (AGLOMERADO), se reemplazaron los nombres de las ciudades/regiones en 2005 por los códigos numéricos correspondientes a 2025. Como también, las variables sobre categorías ocupacionales e inactividad (CAT_OCUP y CAT_INAC), que también fueron estandarizadas siguiendo el esquema numérico de 2025.

Con este procedimiento, garantizamos que la base resultante esté lista para los siguientes pasos del análisis, evitando inconsistencias y asegurando que las comparaciones entre años se realicen sobre variables equivalentes.

Posteriormente, en el punto número uno, generamos la variable *edad*², definida como el cuadrado de la edad reportada en la encuesta. Esta transformación se utiliza frecuentemente porque permite capturar relaciones no lineales: por ejemplo, el efecto de la edad sobre los ingresos o la actividad laboral no suele ser estrictamente lineal, sino que puede mostrar incrementos hasta cierto punto y luego decrecer.

Para explorar la distribución de la edad en la muestra, construimos dos visualizaciones: un histograma de edad (Ver Fig. 1) que muestra la distribución completa de la variable edad para la población analizada (2005 y 2025 unificados). La distribución exhibe una concentración marcada en edades jóvenes y adultas tempranas, con una media de 35 años (M: 34.52, SD: 22.01) ; con un máximo visible en torno a la adolescencia y una disminución progresiva hacia las edades avanzadas; la cola derecha es larga pero con baja densidad relativa, consistente con la menor frecuencia de adultos mayores en la encuesta.

Luego, realizamos un Kernel (Ver Fig. 2) que busca demostrar la distribución de edad por condición de pobreza. Para este gráfico restringimos la muestra a los casos con ingresos válidos y con la variable de pobreza definida, es decir, trabajamos sobre la base respondieron (la misma que construimos en el TP1 a partir de quienes declararon ITF) para evitar sesgos por no respuesta. La comparación revela diferencias claras en la estructura etaria. La curva de pobres presenta su pico en edades más jóvenes y desciende con rapidez a medida que aumenta la edad, mientras que la de no pobres se desplaza hacia edades intermedias y mayores, con una cola más pesada entre los 40 y 70 años. En conjunto, los gráficos sugieren que la pobreza está sobrerrepresentada en tramos etarios tempranos, en tanto que la población no pobre concentra mayor peso relativo en edades adultas, lo que respalda la inclusión de *edad*² para modelar patrones potencialmente curvilíneos.

Luego, construimos la variable *educ* para analizar la cantidad de años de educación formal. Para ello utilizamos de manera conjunta tres variables que indican el nivel educativo más alto alcanzado (CH12), si ese nivel fue finalizado (CH13) y último año aprobado dentro de dicho nivel (CH14). El procedimiento realizado consistió en asignar equivalencias en años de escolaridad a los diferentes niveles, ajustando según la información sobre finalización y último año aprobado. Por ejemplo, si una persona declaró “secundario” como máximo nivel alcanzado (CH12), lo completó (CH13=“Sí”) y el último año aprobado fue “sexto” (CH14), entonces se le asignaron 12 años de educación. Este mismo criterio se aplicó sistemáticamente a todas las observaciones, permitiendo construir una medida continua de años de educación comparable entre individuos y entre años de la encuesta.

Con la variable *educ* ya generada, elaboramos un histograma de su distribución para toda la muestra (Ver Fig. 3). El gráfico muestra concentraciones evidentes en ciertos valores característicos del sistema educativo argentino: alrededor de 6 años (finalización de primaria), 12 años (finalización

de secundaria) y entre 15 y 17 años (niveles terciarios y universitarios). Estos “picos” reflejan las terminalidades típicas del recorrido escolar.

A continuación, realizamos un análisis descriptivo de la nueva variable. Los resultados muestran un promedio de 9,85 años de educación formal, con una desviación estándar de 4,62 años. El valor mínimo es 0 (personas sin escolaridad), la mediana se ubica en 12 años, y el máximo alcanza los 21 años, lo que corresponde a trayectorias educativas universitarias completas o extendidas.

Finalmente, presentamos la distribución de *educ* diferenciada por condición de pobreza. El contraste revela que los no pobres presentan en promedio 10,7 años de educación, mientras que los pobres alcanzan 8,4 años. Además, la mediana es de 12 años en el grupo no pobre y de 9 años en el grupo pobre. Las densidades kernel (Ver Fig. 4) muestran que entre los pobres predomina la concentración en tramos educativos más bajos (finalización de primaria e incompleto de secundaria), mientras que entre los no pobres se observa una mayor representación en secundaria completa y niveles superiores.

Este análisis confirma la fuerte asociación entre nivel educativo y condición de pobreza, mostrando que la educación no solo se distribuye de forma desigual, sino que también constituye un factor clave en la segmentación socioeconómica de la población.

En este paso trabajamos con la variable *ingreso_total_familiar* (ITF), definida en la EPH como el ingreso habitual del hogar. Dado que las bases corresponden a los primeros trimestres de 2005 y 2025, fue necesario actualizar los ingresos de 2005 a pesos de 2025, corrigiendo por el poder de compra y asegurando que las magnitudes fueran comparables entre ambos períodos. Este procedimiento se realizó antes de unir las bases y permite que todas las mediciones de ingreso se expresen en una misma moneda de referencia.

Una vez homogeneizada la variable, construimos dos visualizaciones. El Panel A (Ver Fig. 5) muestra el histograma del ingreso familiar total en la muestra completa, con una línea vertical roja que marca la línea de pobreza promedio. Se observa una fuerte concentración de hogares en los tramos bajos de ingreso, con una cola larga hacia la derecha que representa a los hogares con ingresos muy elevados. La línea de pobreza aparece cercana al primer pico de la distribución, lo cual anticipa que una parte importante de los hogares queda por debajo de ese umbral.

El Panel B (Ver Fig. 6) presenta las densidades kernel del ingreso total familiar, diferenciando entre pobres y no pobres. Para este gráfico, al igual que en los puntos anteriores, trabajamos con la base respondieron, que incluye únicamente los hogares con ingresos válidos. La comparación muestra que la distribución de los pobres se concentra fuertemente en ingresos bajos y cae abruptamente, mientras que la de los no pobres se desplaza hacia la derecha, con mayor densidad en tramos intermedios y altos. Las líneas verticales indican la línea de pobreza promedio en cada grupo y confirman la separación entre ambas distribuciones.

El análisis de esta variable refleja una marcada desigualdad en la distribución de ingresos familiares, con una masa considerable de hogares en situación de vulnerabilidad económica y una minoría con ingresos muy superiores al promedio.

Consiguientemente, construimos la variable *horastrab*, definida como la suma de las horas trabajadas en la ocupación principal (PP3E_TOT) y en ocupaciones secundarias (PP3F_TOT). Este procedimiento se realizó sobre la base respondieron, reemplazando valores faltantes por cero para evitar pérdidas de información. Posteriormente filtramos a los individuos identificados como jefes de hogar (CH03=1), dado que el objetivo es describir la carga horaria de este grupo en particular.

El análisis descriptivo de la nueva variable muestra un promedio de 22,4 horas semanales trabajadas por los jefes de hogar, con una desviación estándar de 27,8 horas. La mediana se ubica en 20 horas, mientras que el valor máximo registrado es de 999 horas, lo cual probablemente corresponda a errores de declaración o valores extremos no representativos. También se observa un valor mínimo de 0, que refleja casos de jefes de hogar desocupados o inactivos.

En conjunto, los resultados indican una distribución heterogénea de las horas trabajadas: mientras una parte de los jefes de hogar trabaja en torno a las 20–40 horas semanales, existe un número significativo que no reporta horas trabajadas y algunos pocos casos extremos que influyen en el promedio.

En resumen de la base final para la región patagónica (misma selección que en el trabajo anterior) tiene un total de 79964 casos (46592 son pertenecientes al año 2005 y 33372 al 2025). En esta región, hay un total de 4123 pobres (2222 pertenecientes a 2005 y 1901 a 2025) y 75841 no pobres (44370 en 2005 y 31471 en 2025). En cuanto a los valores faltantes de la variable pobre es importante destacar que son nulos. Esto se debe, como ya mencionamos anteriormente, a que trabajamos con la base *respondieron*. Esta se creó a partir de aquellos sujetos que reportaron sus ingresos, mientras que los que no se agruparon en otra base llamada *no respondieron*. Para poder hacer análisis a partir de la condición de pobreza, nos pareció útil usar solamente aquellos individuos que tenían este dato. Es por esto que no hay datos faltantes, ya que los mismos fueron descartados a la hora de crear esta base de datos.

Parte II: Métodos No Supervisados

En esta segunda sección se ha centrado el estudio en seis variables¹. Se ha realizado una matriz de correlación (Fig.8), muestra como la mayor correlación (0,97) es entre edad y edad2 lo cual muestra redundancia ya que edad2 es una ampliación de edad. La siguiente correlación más alta es de miembros de hogar con edad(-0.4) y edad2 (-0.39) , esto tiene lógica ya que a medida que

¹ edad, edad2, educación, ingreso total familiar (ITF), el número de miembros en el hogar (2005=IX_TOT y 2025=IX_Tot) y horas trabajadas.

aumenta la edad disminuye la cantidad de personas en un hogar. Después, todas las correlaciones son menores a 0.2 lo cual muestra que no existe una correlación lineal fuerte entre ellas.

Posteriormente, estandarizamos estas variables para aplicar el Principal Component Analysis (PCA) en el gráfico de dispersión (Fig 9). El primer componente principal (edad y edad²) explica el 38,36% de la varianza, y el segundo componente principal (años de educación, ingreso total familiar y horas de trabajo) explica el 24,24% de la varianza, en conjunto, captaron el 62,60% de la varianza total en los datos. Además, esto se puede observar en el gráfico de barras que muestra cuánto aporta cada uno (Fig 11). Por otro lado, el gráfico de cargas del PCA (Fig 10) muestra cómo cada variable contribuye a los dos primeros componentes. En PC1 (38,36% de la varianza), edad y edad² se asocian positivamente, mientras que miembros_hogar lo hace en sentido opuesto, reflejando la relación entre edad y tamaño del hogar. En PC2 (24,24%), las variables educ, horastrab e ITF apuntan en la misma dirección, indicando que este eje resume factores socioeconómicos vinculados a educación, ingresos y participación laboral.

Por otro lado hemos realizado clusters, el primero que se corrió (Fig 12) donde en el eje X se encuentra la edad y en el eje Y se encuentra el ingreso familiar, se ha separado con K=2, no obstante, con k=2 y solo edad e ingreso familiar, K-Means no logra separar correctamente a pobres y no pobres, porque la edad domina la segmentación, para poder predecir esto se debería incluir una mayor cantidad de variables. Luego, utilizamos la inspección *Elbow* (Fig 13) en la cual se detecta que el K ideal debería estar entre 3 y 5 para poder explicar con mayor precisión, en este caso se utilizara K=4 (Fig 14) pero este no termina de diferenciar los detalles entre pobres y no pobres o entre distintas clases socioeconómicas. Por último, se creó un dendograma (Fig 15) esto permite identificar un número adecuado de clusters en el árbol en una cierta altura (distancia). Por ejemplo, en este gráfico se distinguen al menos tres grandes grupos principales, rojo, verde y naranja, lo que indica la existencia de perfiles diferenciados de hogares o individuos según las variables analizadas.

Anexo

Figura 1: Histograma de edad




Figura 2: Kernel de distribución de edad por condición de pobreza




Figura 3: Histograma de distribución de la educación




Figura 5: Histograma y Kernel del ingreso total familiar (ITF)




Figura 6: Matriz de correlación entre edad, edad2, educ, ingreso_total_familiar (ITF), el número de miembros en el hogar (2005=IX_TOT y 2025=IX_Tot) y horastrab.




Fig 7

PCA: Scatter plot del Primer vs Segundo componente para Patagonia




Fig 8




Fig 9: Ratio de varianza de los componentes explicada




Fig 10 CLuster k-medias de Edad vs ITF con K=2




Fig 11- Prueba *Elbow* para k óptimo




Fig 12-CLuster k-medias de Edad vs ITF con K=4




Fig 13- Análisis de clustering jerárquico

